


K-Nearest Neighbors (KNN) : L'Algorithme Décrypté

Comprendre la mécanique, les limites et l'impact du modèle de Machine Learning le plus intuitif.

Une exploration visuelle de la classification par proximité.


Réalisé par : Ferdaous Attiou



L'Intuition Fondamentale : Qui se ressemble s'assemble

Le KNN repose sur un postulat simple : les points de données similaires se trouvent à proximité les uns des autres.


Pour identifier une nouvelle donnée, il suffit d'observer ses voisins immédiats.



Une Mécanique, Deux Missions


Bien qu'il s'agisse d'un apprentissage supervisé, le KNN s'adapte à la nature du résultat attendu.

Classification




Résultat : Catégorie Carré Jaune

Régression



Résultat : Valeur Continue 220k €

Sous le Capot : L'Algorithme Paresseux




Le Concept de 'Lazy Learning' : Contrairement à d'autres modèles, le KNN n'a pas de phase d'entraînement préalable. Il mémorise toutes les données et retarde tout calcul jusqu'au moment exact de la prédiction.

Les Deux Seuls Leviers de Commande

La simplicité du KNN réside dans son absence de paramètres complexes. L'algorithme entier repose sur la définition de la distance et la taille du voisinage.

Métrique de Distance



Distance Euclidienne :



$$d(p, q) = \sqrt{\sum (q_i - p_i)^2}$$

Distance de Manhattan :

$$d(p, q) = \sum |q_i - p_i|$$

Définit comment l'espace est mesuré (ex: Distance Euclidienne ou de Manhattan). C'est la règle mathématique qui trace les frontières de décision.


Le Paramètre K



Définit le nombre exact de voisins à consulter avant de prendre une décision.


Le Syndrome de Boucles d'Or : Choisir 'K'

Règle d'Or : Toujours choisir un nombre impair pour K afin d'éviter les égalités lors du vote de classification.




Surapprentissage (Overfitting)

Le modèle 'apprend par cœur'
et capte le bruit.



L'Équilibre Optimal

Frontière lisse et logique.




Sous-apprentissage (Underfitting)

Lissage extrême, perte de
précision spatiale.


La Limite du Modèle : La Malédiction de la Dimensionnalité

En ajoutant trop de caractéristiques (poids, taille, couleur...), l'espace devient si vaste que tous les points semblent équidistants.


2D



3D



N-Dimensions



Le Phénomène de Plafonnement : Au-delà d'un nombre optimal de variables, l'ajout de nouvelles dimensions ne fait qu'augmenter le bruit et les erreurs de classification, surtout si l'échantillon est petit.

Matrice Diagnostique : Forces et Faiblesses

+ Forces


- **Simplicité** : Très facile à implémenter. Idéal comme premier classificateur.
- **Adaptabilité Instantanée** : S'ajuste immédiatement aux nouvelles données sans réentraînement.
- **Minimaliste** : Seulement deux hyperparamètres (K et Distance).

— Faiblesses

- **Gourmand en Mémoire** : Doit stocker l'intégralité du jeu de données en mémoire.
- **Lenteur à l'Échelle** : Les calculs ralentissent drastiquement à mesure que les données augmentent.
- **Sensible au Bruit** : Vulnérable aux valeurs aberrantes si K est mal ajusté.

Le KNN dans le Monde Réel


Data Science & Prétraitement



Data Science & Prétraitement

Imputation des données manquantes. Le KNN excelle pour estimer et combler les valeurs absentes dans de vastes bases de données en observant les voisins de l'entrée incomplète.

Finance & Marchés



Finance & Marchés

Utilisé pour les prévisions boursières, les taux de change, le trading de contrats à terme et la détection d'analyses de blanchiment d'argent.

Santé & Génomique



Santé & Génomique

Prédiction des risques de crises cardiaques et de cancer de la prostate en calculant les expressions génétiques les plus probables.

Un algorithme imparfait mais redoutable d'efficacité lorsque le contexte spatial a du sens.